

Entrega II Proyecto Procesamiento de Datos



Isaías Acosta Herrera

Tomas Felipe Guerra Hernandez

Juan Felipe González Quintero

Diego Alejandro Jara Rojas

Pontificia Universidad Javeriana de Colombia

Procesamiento de Datos

John Corredor

Bogotá, Colombia

14 de Noviembre de 2025

ENTENDIMIENTO DEL PROBLEMA

Nueva York, como la capital del mundo, es una de las ciudades con mayor población y con mayor influencia en el mundo. A pesar de esto, la ciudad enfrenta desde hace décadas retos sociales y urbanos derivados de esta alta densidad poblacional, desigualdad económica y compleja dinámica social. Nueva York cuenta con más de 8.5 millones de habitantes, distribuidos en los cinco distritos (Manhattan, Brooklyn, Queens, Bronx y Staten Island), que a pesar de compartir el mismo marco metropolitano, reflejan realidades profundamente diversas en varios aspectos.

Brooklyn y Queens son los distritos más poblados, con más de 2.7 y 2.4 millones de residentes respectivamente, seguidos de Manhattan, el Bronx y Staten Island, cuya población ronda los 1.6, 1.5 y 0.5 millones. Esta distribución, lejos de ser solo demográfica, evidencia las desigualdades estructurales que marcan la vida urbana: diferencias notorias en calidad de vida, ingreso, seguridad y acceso a la educación.

A pesar de ser uno de los centros financieros y culturales más importantes del mundo, Nueva York enfrenta altos niveles de pobreza y criminalidad, problemáticas que se ven reflejadas directamente en sus indicadores de arrestos, niveles de educación y distribución de ingresos.

A partir de los reportes oficiales del NYPD (New York Police Department), los delitos y arrestos han variado significativamente dependiendo de las distintas zonas. En vecindarios con mayores índices de pobreza (partes del Bronx y Brooklyn) se concentra la mayor cantidad de arrestos y las tasas más altas de reincidencia, mientras que áreas con mayor desarrollo económico presentan cifras notablemente menores. Estos patrones sugieren la posible existencia de relaciones entre las condiciones socioeconómicas, la calidad educativa y la incidencia delictiva.

Comprender cómo se relacionan estos factores —población, condiciones socioeconómicas, educación y criminalidad— resulta esencial para el diseño de políticas públicas efectivas. En este contexto, el Estado de Nueva York ha contratado a nuestro equipo como consultor para analizar y cruzar grandes volúmenes de datos históricos, con el objetivo de identificar patrones y posibles determinantes de la criminalidad urbana, fortaleciendo así la toma de decisiones basada en evidencia.

PREGUNTA PROBLEMA

¿En qué medida se relacionan los niveles de pobreza y educación con la incidencia de arrestos y delitos en los diferentes distritos de la ciudad de Nueva York?

OBJETIVOS

Objetivo general:

Desarrollar un análisis usando las herramientas de Big Data para identificar patrones entre los indicadores de arrestos, pobreza y educación en la ciudad de Nueva York. A partir de esto, proponer un plan de acción que permita al gobierno tomar decisiones basadas en evidencia.

Objetivos específicos:

- Analizar la distribución de los arrestos registrados por el NYPD en cuanto a sus ubicaciones.
- Relacionar los indicadores de pobreza y nivel educativo con la incidencia de arrestos por distrito.
- Detectar las respectivas correlaciones y posibles causas estructurales de las disparidades sociales y criminales.
- Formular hallazgos accionables y realizar las respectivas recomendaciones para políticas de seguridad y desarrollo social.

RESUMEN EJECUTIVO

La Ciudad de Nueva York enfrenta una compleja relación entre desigualdad socioeconómica, niveles de educación y criminalidad. A partir del análisis de tres fuentes oficiales —arrestos del NYPD, pobreza según la NYCgov Poverty Measure (2018) y criminalidad escolar— se identificaron patrones que revelan la concentración de arrestos y delitos graves en los distritos del Bronx, Brooklyn y Manhattan, los cuales presentan también mayores brechas de pobreza y menor acceso a la educación superior.

En la primera entrega, se realizó un análisis exploratorio exhaustivo que permitió limpiar, integrar y visualizar los datos de manera coherente. Se evidenció que el Bronx, pese a tener menor población que Brooklyn, presenta tasas de criminalidad casi equivalentes, con predominancia de jóvenes entre 18 y 30 años involucrados en delitos de agresión, robo y posesión de drogas. Manhattan, por su parte, refleja un contraste: a pesar de sus altos niveles educativos y bajos índices de pobreza, se mantiene una incidencia significativa de delitos vinculados con la actividad económica y comercial.

Esta segunda entrega profundiza en la preparación técnica, transformación, modelado y evaluación de los datos con el uso de Spark MLlib, con el objetivo de enriquecer el estudio mediante el uso de técnicas de aprendizaje supervisado y no supervisado, fortaleciendo la capacidad predictiva y analítica del modelo.

METODOLOGÍA:

PREPARACIÓN DE LOS DATOS PARA TOMA DE DECISIONES:

El procesamiento de datos fue una etapa crucial dentro del análisis, ya que permitió al equipo garantizar la calidad y fiabilidad de la información utilizada para la toma de decisiones. Los datos analizados provenían de distintas fuentes oficiales de la ciudad de Nueva York ya mencionadas anteriormente. En estos archivos fue necesario realizar un trabajo cuidadoso de limpieza, transformación y estandarización de variables para desarrollar un análisis integral de los respectivos datos.

1. Revisión exploratoria de los datos

Para empezar, se realizó una revisión exploratoria del contenido de los datasets, verificando la cantidad de registros, tipos de variables y rangos de valores. Este proceso permitió identificar columnas redundantes o con poca relevancia analítica, las cuales fueron descartadas para optimizar la base de datos final. También se realizó una verificación de los tipos de datos para asegurar su correcta lectura por parte de las herramientas de análisis y visualización. En algunos casos, fue necesario realizar conversiones de formato.

2. Limpieza y depuración

Después de eso, se llevó a cabo la limpieza de valores nulos, duplicados y atípicos, con el fin de evitar sesgos o errores en los resultados. Se identificaron registros incompletos en variables clave como de cada uno de los datasets. En estos casos, se aplicaron distintos métodos de depuración, como la eliminación de registros con valores faltantes cuando representaban un porcentaje menor al total, o la imputación de valores en casos donde el patrón de datos permitía hacerlo con coherencia. De esta manera, se redujo la presencia de inconsistencias y se logró una base más precisa para el análisis posterior.

3. Estandarización de variables

Posteriormente, se realizó un proceso de estandarización de las variables para permitir la comparación entre los diferentes conjuntos de datos. Esto implicó unificar los nombres de los distritos, los códigos de delitos y las categorías educativas, entre muchos otros, además de establecer escalas comunes de medida. Las variables que representaban niveles de pobreza o educación se ajustaron para mantener el mismo formato y facilitar la comparación directa entre distritos. Esta estandarización fue muy importante para integrar los resultados y construir visualizaciones consistentes.

4. Integración de fuentes

Por último, ya teniendo depurada y estandarizada la información, se llevó a cabo la verificación final de la calidad de los datos mediante análisis descriptivos básicos y exploración visual. Se revisaron distribuciones, conteos y promedios para asegurarse de que los valores fueran coherentes con la realidad esperada y con fuentes oficiales de referencia. Además de esto, se comprobó que no existieran valores nulos ni incongruencias entre variables dependientes, para obtener así una base de datos limpia y confiable.

5. Filtros


Los filtros más importantes que se aplicaron fueron tanto el temporal como el geográfico. En cuanto al filtro temporal se mantuvieron únicamente los registros correspondientes al año 2018 en todos los conjuntos, garantizando consistencia temporal y comparabilidad entre fuentes. Por otro lado, en cuanto al filtro geográfico se excluyeron registros sin correspondencia geográfica (coordenadas nulas o distritos fuera de B, K, M, Q, S) asegurando así integridad espacial del análisis, la cual va a ser muy necesaria para correlaciones por distrito.

6. Transformaciones

Se realizaron diversas transformaciones a los datos para su análisis. Primero, se codificaron las variables categóricas `ARREST_BORO`, `LAW_CAT_CD`, `SEX`, `PERP_RACE` y `NYCgov_Pov_Stat`. Luego, se efectuó una agrupación por distrito utilizando las funciones *groupBy()* y *agg()*, obteniendo métricas promedio de arrestos, nivel de pobreza y educación, lo cual permite analizar correlaciones entre distritos e identificar tendencias. Finalmente, se creó la variable compuesta “Tasa de Criminalidad Escolar Total”, calculada como una suma ponderada de incidentes graves y leves normalizados por cantidad de escuelas, con el propósito de facilitar la relación entre el entorno educativo, la pobreza y los arrestos.

RESPUESTAS A PREGUNTAS DE NEGOCIO

- 1. ¿Cómo se comparan los niveles de arrestos entre los distintos distritos de Nueva York en relación con la cantidad de crímenes escolares reportados en cada uno?**




La gráfica muestra que existe una tendencia consistente entre los niveles generales de arrestos y la cantidad de crímenes escolares en los distritos de Nueva York. Bronx y Brooklyn destacan como los distritos con las cifras más altas en ambas variables: tienen los mayores niveles de arrestos y también los mayores niveles de crímenes escolares. Esto sugiere una posible relación entre la criminalidad general del distrito y los incidentes escolares.

Por el contrario, Staten Island presenta los valores más bajos tanto en arrestos como en crímenes escolares, lo cual refuerza esta tendencia. Manhattan y Queens se encuentran en una zona intermedia, manteniendo proporciones relativamente coherentes entre ambas categorías.

En conjunto, la gráfica indica que, aunque los crímenes escolares ocurren en una escala mucho menor que los arrestos totales, los distritos más afectados por criminalidad urbana también parecen registrar más incidentes dentro del entorno escolar.

2. ¿Qué relación existe entre las causas de arresto y las condiciones de pobreza de las personas involucradas en cada distrito?




La gráfica muestra que la pobreza está asociada principalmente con el volumen total de arrestos, pero no con un tipo particular de delito. Distritos como el Bronx y Brooklyn, que presentan los niveles de pobreza más altos, acumulan también el mayor número de arrestos; sin embargo, la distribución entre categorías delictivas (agresiones, drogas, robos/hurtos, tránsito, etc.) es relativamente similar a la de otros distritos. Esto indica que la pobreza no concentra ni incrementa un delito específico, sino que está relacionada con una mayor cantidad de detenciones en general.

En contraste, Manhattan y Queens muestran niveles intermedios de pobreza y, de manera coherente, un volumen moderado de arrestos, mientras que Staten Island, el distrito más favorecido económicamente, registra el número más bajo. La consistencia de esta tendencia sugiere que las condiciones socioeconómicas influyen en la frecuencia total de interacciones con el sistema de justicia más que en la naturaleza del delito cometido.

El uso conjunto de barras apiladas y la línea de pobreza promedio permite confirmar que, aunque los tipos de crímenes se distribuyen de manera comparable entre distritos, es el tamaño total de la carga delictiva el que varía en función de la pobreza. En síntesis, la desventaja económica no define el tipo de delito, pero sí la magnitud global de los arrestos.

3. ¿Cuál es la correlación entre el nivel educativo promedio de la población y la cantidad de arrestos registrados en los distritos con mayores índices de pobreza?




La gráfica muestra una relación inversa entre el nivel educativo promedio y la cantidad de arrestos en los distritos analizados. El Bronx, que presenta el nivel educativo promedio más bajo, también muestra un volumen elevado de arrestos en comparación con los otros distritos. En contraste, Manhattan, donde el nivel educativo es significativamente más alto, registra una cantidad relativamente menor de arrestos, lo que sugiere que los niveles educativos superiores pueden estar asociados con una menor exposición a situaciones que resulten en detenciones. Brooklyn, con un nivel educativo intermedio, presenta cifras de arrestos más altas que Manhattan, lo que refuerza la tendencia general: a menor nivel educativo, mayor número de arrestos.

En conjunto, la gráfica sugiere una correlación negativa entre ambas variables: a medida que aumenta el nivel educativo promedio en un distrito, la cantidad de arrestos tiende a disminuir. Aunque la relación no es perfectamente lineal debido a diferencias propias de cada zona, la tendencia general indica que la educación podría actuar como un factor protector frente a comportamientos delictivos o situaciones de riesgo que derivan en arrestos.

Para analizar esta relación se utilizó un gráfico combinado en el que las barras representan la cantidad de arrestos por distrito y la línea muestra el nivel educativo promedio. Este formato permite observar simultáneamente ambas variables y visualizar cómo los cambios en el nivel educativo se relacionan con variaciones en el número de arrestos, evidenciando una asociación negativa clara entre educación y criminalidad.

4. ¿En qué distritos se concentran los niveles más altos de criminalidad escolar y cómo se relacionan con el contexto socioeconómico de esas zonas?




La gráfica muestra que los niveles más altos de criminalidad escolar se concentran en el Bronx y Brooklyn, donde las barras que representan los incidentes escolares superan los 2,700 casos. En contraste, Manhattan presenta una cifra notablemente menor, cercana a 1,800 crímenes escolares. Esta diferencia evidencia que los distritos con mayores problemáticas sociales son también los que registran más incidentes de violencia, acoso o conductas delictivas dentro de las escuelas.

Al observar la línea que representa la brecha de pobreza promedio, se aprecia que el Bronx es el distrito con la mayor desigualdad socioeconómica, seguido por Brooklyn. Ambas zonas coinciden con los niveles más altos de criminalidad escolar, lo que sugiere que la precariedad económica contribuye a generar entornos escolares más vulnerables y propensos a conflictos. Por el contrario, Manhattan presenta la brecha de pobreza más baja y, al mismo tiempo, los niveles más reducidos de criminalidad escolar, reforzando la relación entre contexto socioeconómico y seguridad educativa.

En conjunto, la gráfica evidencia una relación directa: los distritos con mayor desigualdad económica presentan los índices más altos de criminalidad escolar. Esto indica que las condiciones socioeconómicas del entorno influyen significativamente en las dinámicas escolares, afectando tanto el clima institucional como la frecuencia de incidentes delictivos dentro de los centros educativos.

5. ¿En qué medida la pobreza de un distrito influye en la cantidad de arrestos registrados en esa zona?




La gráfica muestra una relación consistente entre la pobreza promedio de cada borough y la cantidad total de arrestos registrados. El Bronx y Brooklyn presentan simultáneamente las cifras más altas de detenciones y los niveles de pobreza más elevados, lo que sugiere una asociación directa entre desventaja económica y mayor participación o exposición al sistema de justicia penal. En estos distritos, la combinación de necesidades económicas, menor acceso a recursos y desigualdad estructural podría contribuir a la concentración de arrestos.

En contraste, Staten Island y Queens registran los niveles más bajos de pobreza y, al mismo tiempo, muestran las cifras más reducidas de arrestos dentro del conjunto analizado. Manhattan ocupa una posición intermedia: aunque tiene un volumen considerable de arrestos, su nivel de pobreza es notablemente menor que el de Bronx y Brooklyn, lo que indica que existen otros factores sociales y demográficos que también influyen, pero sin romper la tendencia general observada.

En conjunto, la gráfica evidencia que los boroughs con mayores niveles de pobreza tienden a concentrar también el mayor número de arrestos. Esta relación sugiere que la pobreza actúa como un factor estructural que incrementa la probabilidad de interacciones con el sistema penal, ya sea por condiciones de vulnerabilidad, menor acceso a oportunidades o mayor exposición a situaciones de riesgo.

6. ¿Hasta qué punto el nivel educativo promedio de la población reduce o aumenta los casos de criminalidad escolar?




La gráfica muestra que existe una relación inversa entre el nivel educativo promedio de la población y los casos de criminalidad escolar. Manhattan, que presenta el nivel educativo promedio más alto, registra también los valores más elevados de criminalidad escolar, lo cual indica que la relación no es lineal ni automática. Sin embargo, al observar el resto de los boroughs se evidencia una tendencia más clara: Brooklyn, Queens y Staten Island, con niveles educativos intermedios, presentan cifras moderadas de criminalidad escolar, mientras que el Bronx, con el nivel educativo más bajo, exhibe una de las tasas más altas dentro del conjunto analizado. Esto sugiere que la educación puede ser un factor protector, pero su efecto puede variar según condiciones específicas de cada distrito.

En general, la línea que representa el nivel educativo promedio desciende de forma marcada desde Manhattan hasta el Bronx, mientras que las barras de criminalidad escolar aumentan de nuevo en este último. Esta asociación indica que, en los distritos donde la formación académica es más limitada, los entornos escolares tienden a ser más vulnerables a conflictos, violencia o incidentes disciplinarios. Por el contrario, en zonas donde la población cuenta con mayores niveles educativos, se observan entornos escolares relativamente más estables.

En conjunto, la gráfica sugiere que el nivel educativo promedio influye en la criminalidad escolar en sentido negativo: a menor educación en los hogares, mayores son los niveles de incidentes en las instituciones educativas. Aunque existen excepciones (como el caso de Manhattan) la tendencia general muestra que la educación contribuye a generar dinámicas familiares y comunitarias que reducen la probabilidad de comportamientos conflictivos dentro de las escuelas.

7. ¿En qué medida los distritos con mayores tasas de pobreza presentan también más causas de arresto relacionadas con delitos menores?




La gráfica evidencia que los distritos con mayores niveles de pobreza tienden a presentar también un número significativamente más alto de arrestos por delitos menores. El Bronx, que registra la mayor brecha de pobreza, muestra también uno de los volúmenes más altos de detenciones por infracciones menores, superando ampliamente los registros de delitos mayores. Brooklyn presenta un patrón similar: su nivel de pobreza se encuentra entre los más elevados y, al mismo tiempo, los arrestos por delitos menores superan con claridad a los arrestos por delitos mayores. Este comportamiento sugiere que los contextos económicamente vulnerables están más asociados a conductas delictivas de baja escala, posiblemente relacionadas con necesidades inmediatas o actividades informales.

En contraste, distritos como Manhattan y Queens, donde la brecha de pobreza es más baja, muestran una distribución más equilibrada entre delitos menores y mayores, aunque los menores siguen siendo predominantes. Staten Island, con los niveles de pobreza más reducidos, registra también la menor cantidad absoluta de arrestos en ambas categorías, reforzando la tendencia general: a menor pobreza, menor volumen de infracciones y menor predominio de delitos menores.

En conjunto, la gráfica apunta a una relación directa entre pobreza y prevalencia de arrestos por delitos menores. Los distritos con mayor desventaja económica concentran la mayor parte de este tipo de detenciones, lo que sugiere que la pobreza no solo incrementa la exposición al sistema penal, sino que orienta los patrones delictivos hacia infracciones de menor escala asociadas a situaciones de precariedad y falta de oportunidades.

8. ¿Cómo varía la relación entre pobreza y criminalidad escolar entre distritos como Brooklyn, el Bronx y Manhattan?



La gráfica muestra que la relación entre pobreza y criminalidad escolar varía de manera clara entre el Bronx, Manhattan y Brooklyn. El Bronx, que presenta el nivel de pobreza promedio más alto, registra también la mayor cantidad de crímenes escolares entre los tres distritos analizados. Esto sugiere que en este borough la pobreza está estrechamente asociada con un entorno escolar más vulnerable, donde los incidentes de violencia o conflicto ocurren con mayor frecuencia.

En Manhattan, la tendencia es distinta: aunque la criminalidad escolar se mantiene relativamente alta, el nivel de pobreza es notablemente más bajo que en el Bronx. Esto indica que factores adicionales —como la densidad escolar, el tamaño de las instituciones o diferencias en reportes administrativos— pueden influir en la presencia de incidentes en las escuelas, reduciendo la fuerza de la relación directa entre pobreza y criminalidad escolar en este distrito.

Brooklyn se ubica en una posición intermedia. Su nivel de pobreza es menor que el del Bronx pero mayor que el de Manhattan, y sus niveles de criminalidad escolar siguen una lógica similar: no alcanza los valores del Bronx, pero supera a Manhattan en ciertos casos. Esta combinación sugiere que, aunque la pobreza influye en los incidentes escolares, la relación no es completamente lineal y depende de características locales del distrito.

En conjunto, la gráfica evidencia que la relación entre pobreza y criminalidad escolar existe, pero su intensidad varía entre distritos. En el Bronx es más marcada, en Brooklyn es moderada y en Manhattan es más débil, lo que demuestra que la pobreza es un factor importante, aunque no el único que determina la seguridad escolar en cada zona.

SELECCIÓN DE TÉCNICAS DE APRENDIZAJE DE MÁQUINA


Para abordar el análisis de los distintos conjuntos de datos, se seleccionaron técnicas de aprendizaje de máquina tanto supervisadas como no supervisadas, dependiendo de la naturaleza del propio dataset y de las variables disponibles. A continuación se enuncia la técnica usada en cada uno de los conjuntos de datos así como todo el proceso realizado desde la fase de preprocesamiento, aplicación de la técnica y los resultados obtenidos.

CONJUNTO DE DATOS DE ARRESTOS (APRENDIZAJE SUPERVISADO)

En el análisis de arrestos, se empleó un enfoque supervisado mediante un Random Forest, orientado a modelar la probabilidad de arresto según el tipo de delito. El modelo considera variables demográficas y espaciales con el fin de comprender los factores asociados a la criminalidad y las diferencias entre distritos. Esta técnica resulta adecuada para problemas de clasificación binaria o multiclase y permite estimar la influencia de múltiples variables predictoras sobre la ocurrencia de un evento.

1. Preprocesamiento de datos.

Para hacer uso del random forest se debe de ver si las variables en el dataset tienen una buena relación con el resto de variables para que el aprendizaje encuentre patrones entre estos y nos de los resultados que esperamos. Para esto se hace uso de la matriz de correlación de las variables numéricas de los arrestos.



La matriz de correlación muestra que la mayoría de las variables numéricas presentan correlaciones muy bajas entre sí, lo que indica que no existen relaciones lineales fuertes dentro del dataset. Las únicas correlaciones altas corresponden a las variables de ubicación (X_COORD_CD, Y_COORD_CD, Latitude y Longitude), lo cual es esperable porque representan la misma información espacial en diferentes sistemas de coordenadas.

Dado que la variable objetivo (CategoriaDelito) es categórica, no aparece en la matriz y no es posible evaluar su relación lineal con las demás variables mediante este método. Sin embargo, el hecho de que las variables numéricas no tengan correlaciones fuertes sugiere que un modelo lineal, como la regresión logística multiclase, podría tener dificultades para separar adecuadamente las clases. Por esta razón, métodos no lineales como Random Forest tienden a ajustarse mejor a este tipo de datos.

2. Selección, limpieza y categorización de los datos.

Para construir el modelo predictivo se realizó una selección de variables basada en su posible relación con los motivos de arresto. Se eligieron aquellas características que, teóricamente y según la exploración inicial, podrían aportar información relevante para predecir la categoría del delito. Las variables seleccionadas fueron:

- Distrito donde ocurrió el arresto.
- Sexo del perpetrador.

- Raza del perpetrador.
- Edad del perpetrador.
- Latitud, longitud del lugar del arresto

Posteriormente se llevó a cabo un proceso de limpieza que incluyó la identificación y manejo de valores nulos, la estandarización de formatos y la codificación de variables categóricas, necesarias para que los algoritmos de aprendizaje automático pudieran procesarlas correctamente.

- Agrupación de categorías delictivas.

El método de Random Forest requiere trabajar con variables objetivo claramente definidas. En el dataset original existían numerosas categorías delictivas, muchas de ellas muy específicas, por ejemplo:

- OTHER TRAFFIC INFRACTION
- ANTICIPATORY OFFENSES
- HOMICIDE-NEGLIGENT, UNCLASSIFIED
- CHILD ABANDONMENT/NON SUPPORT 1
- NEW YORK CITY HEALTH CODE
- POSSESSION OF STOLEN PROPERTY 5
- VEHICLE AND TRAFFIC LAWS
- ABORTION
- KIDNAPPING & RELATED OFFENSES
- HOMICIDE-NEGLIGENT-VEHICLE
- OFF. AGNST PUB ORD SENSBLTY &
- FELONY ASSAULT
- ALCOHOLIC BEVERAGE CONTROL LAW
- OFFENSES RELATED TO CHILDREN
- CRIMINAL MISCHIEF & RELATED O
- THEFT-FRAUD
- MURDER & NON-NEGL. MANSLAUGHT
- JOSTLING
- MISCELLANEOUS PENAL LAW
- ARSON

Sin embargo, trabajar con tantas categorías genera un problema para la modelación: algunas poseen muy pocos registros y otras son demasiado específicas, lo que dificulta que el modelo aprenda patrones significativos.

Para solucionar esto, se reagrupan todas estas categorías en 7 grandes grupos delictivos, creando así la variable objetivo (*label*) denominada *CategoriaDelito*. Los grupos definidos fueron:

- Agresiones.
- Robos/Hurtos.
- Drogas.
- Armas.
- Tránsito.
- Desobediencia/Citaciones.
- Otros

Esta reclasificación permitió reducir la complejidad del problema, equilibrar mejor la distribución de clases y aumentar la capacidad del modelo para identificar patrones de predicción.

3. Resultados del modelo e interpretación.

Para responder esta pregunta buscamos predecir el motivo del arresto (agresiones, robos/hurtos, drogas, armas, tránsito y desobediencia/citaciones) utilizando información del perpetrador y del lugar donde ocurrió el arresto. Para esto, utilizamos el algoritmo Random Forest, un método de aprendizaje supervisado muy adecuado cuando se trabaja con datos reales, complejos y con muchas categorías.

Random Forest es un algoritmo que construye muchos árboles de decisión diferentes y combina sus resultados para tomar una decisión final más precisa y estable.

Es como consultar a varios “expertos” en lugar de solo uno: cada árbol analiza los datos de forma distinta, y el modelo final elige la categoría más votada.

En el contexto de nuestro proyecto, esto es útil porque:


- Los datos de arrestos tienen relaciones muy complejas, no lineales.
- Hay muchas variables categóricas: distrito, sexo, raza, motivo del arresto.
- Existen patrones débiles (la matriz de correlación muestra correlaciones bajas), por lo que un solo modelo simple no sería suficiente.
- Random Forest es resistente al ruido y valores atípicos, algo común en datos policiales.

Random forest crea múltiples árboles, cada uno con una muestra aleatoria de datos distintos del dataset. Para que se tengan varias combinaciones.

En cada subdivisión del árbol se tienen en cuenta algunas variables entre distrito, sexo, raza, edad, latitud, longitud. Para así en base a los distintos datos tratar de predecir el motivo del arresto, al final la categoría más votada entre los distintos árboles es la que queda como porcentaje de acierto de ese motivo de delito.

- Evaluación de resultados.

Al evaluar el modelo de Random Forest multiclase, se obtuvo una precisión (accuracy) del 33% y un F1 Score del 26%. Estos valores indican que el modelo presenta un desempeño limitado al momento de predecir correctamente la categoría del delito asociado a un arresto. Esto se puede ver en la gráfica sacada para ver estas predicciones:



La gráfica muestra las probabilidades que el modelo asignó a cada categoría de delito para un ejemplo específico cuya categoría real es Agresiones. Aunque el modelo acertó la predicción porque Agresiones obtuvo la probabilidad más alta (alrededor del 30%), las probabilidades de “Otros” (28%) y “Robos/Hurtos” (24%) están muy cerca, lo que revela que el modelo no está muy seguro y percibe similitud entre estas categorías. Las demás clases tienen probabilidades muy bajas, por lo que prácticamente las descarta. En resumen, el modelo acierta, pero muestra poca confianza y cierta confusión entre clases parecidas, lo que sugiere que podría mejorar si se ajustan los datos o se agregan variables que hagan más distinguibles las categorías.

Estos resultados se explican por factores previamente analizados:

- Las variables disponibles en el dataset (sexo, edad, raza, distrito, latitud y longitud) muestran baja correlación con los motivos del arresto.
- Esto hace que el modelo tenga poca información útil para identificar patrones sólidos que permitan distinguir entre los diferentes tipos de delitos.
- Debido a esta débil relación entre las características y la variable objetivo, el Random Forest no logra separar las clases de forma clara, produciendo una precisión baja.
- El F1 Score, que combina precisión y sensibilidad, confirma que el modelo es débil para reconocer correctamente las categorías de delito, especialmente en un escenario con clases desbalanceadas y variables poco predictivas.

En conclusión, el desempeño del modelo no se debe al algoritmo en sí, sino a la limitada capacidad predictiva de los datos disponibles, que no contienen la información necesaria para generar predicciones confiables sobre el motivo del arresto.

CONJUNTO DE DATOS DE ESCUELAS (APRENDIZAJE NO SUPERVISADO)

En el caso del dataset de de escuelas, se aplicó un enfoque no supervisado, concretamente la técnica de clustering, utilizando el algoritmo K-Means. El objetivo de aplicar esta técnica fue identificar grupos de instituciones educativas de acuerdo a los tipos de crímenes que allí se cometen. Esta metodología permite descubrir patrones y segmentaciones naturales dentro de la criminalidad en las escuelas. A continuación se detalla el proceso que fue seguido para poder implementar esta técnica correctamente.

1. Preprocesamiento de datos

Para poder aplicar correctamente la técnica de clustering k-means, es necesario eliminar las variables que tengan una alta correlación entre sí, es decir, que los cambios que se produzcan en las mismas estén estrechamente y consistentemente asociados. Para poder determinar cuáles de las variables del conjunto de datos tienen este tipo de correlación podemos utilizar las herramientas de Pyspark y calcular la matriz de correlación entre variables numéricas, que por medio de una escala de rojos y azules nos mostrará que tan fuerte es la correlación entre cada par de variables. La matriz de correlación para este conjunto de datos es la que se muestra a continuación:




Figura 1. Matriz de correlación - Escuelas

Para entender la figura 1, se debe partir del hecho de que esta matriz funciona similar a como lo hace un mapa de calor en el sentido en que entre más azul sea la coloración del cuadrante que representa la relación entre dos variables, menor es su correlación. Por otro lado, cuando se ven tonos más rojizos lo que se sigue es que la correlación entre las dos variables es mayor. En este caso, debido a que todos los promedios presentan una correlación muy fuerte (mayor a 0.9), estas variables deben ser eliminadas de la selección final que será utilizada para construir el modelo de aprendizaje no supervisado.

Además de aquellas que eliminamos vía análisis de correlación, también se deben filtrar las variables para que las utilizadas en la técnica de aprendizaje de máquina sean únicamente numéricas no categóricas ni ordinales ya que esto podría representar ruido para el modelo y así sería difícil que se encuentre una buena segmentación de clústers. El resultado de aplicar estos filtros de variables resulta en la elección de las siguientes variables:

- **Major N:** Indicador de criminalidad más grave dentro de cada escuela.
- **Oth N:** Refleja la frecuencia de incidentes no mayores, complementando la categoría anterior.

- **NoCrim N:** Permite medir el nivel general de conflicto en la escuela, incluso si no llega a ser crimen.
- **Prop N:** Mide la afectación a la propiedad dentro del entorno escolar.
- **Vio N:** Es un indicador clave para medir la inseguridad violenta en el entorno escolar.

2. Aplicación de la técnica de aprendizaje de máquina

Como se mencionó previamente, para este conjunto de datos se optó por utilizar la técnica de clustering k-means, un algoritmo que realiza la capacitación de un modelo que agrupa objetos similares. Esto se logra estableciendo la correspondencia de cada observación en el conjunto de datos de entrada con un punto en el espacio dimensional n (donde n es el número de atributos de la observación).

Para la implementación de esta técnica se utilizaron los recursos de la biblioteca MLLIB, particularmente los recursos de VectorAssembler y StandardScaler para construir un vector con las “features” que serán incluidas en el dataframe que se usará y escalar las variables incluidas para que el entrenamiento funcione de forma correcta.

Luego de esto, se ejecuta una de las partes centrales de esta técnica, la cuál se basa en la escogencia del número de clústers k óptimo para el entrenamiento del modelo. Dado que no conocemos a priori cuántos grupos naturales existen en los datos de criminalidad escolar, **se evalúan diferentes valores de k desde 2 hasta 9 clusters**. Para cada valor de k , se entrena un modelo K-Means y se calcula el **Silhouette Score**, una **métrica que mide qué tan bien definidos están los clusters** (valores cercanos a 1 indican clusters bien separados y cohesionados, mientras que valores cercanos a 0 o negativos indican clusters mal definidos o solapados). Al comparar los scores obtenidos, se puede identificar el valor de k que produce la mejor segmentación de las escuelas según sus patrones de criminalidad.

Pero ya que el silhouette score no es una métrica que pueda darnos una noción completa sobre cuál es el k óptimo, se debe equilibrar con los resultados de la aplicación de otras métricas adicionales.

En este caso, se implementa una **evaluación multi-métrica para determinar el número óptimo de clusters**, entrenando modelos K-Means con valores de k desde 2 hasta 10 y calculando cuatro métricas complementarias para cada configuración. Se computan **dos variantes del Silhouette Score utilizando diferentes medidas de distancia (euclidiana y coseno)** para capturar distintas nociones de similitud entre escuelas, **el WSSSE (Within Set Sum of Squared Errors)** que mide la compacidad de los clusters mediante la suma de distancias al cuadrado dentro de cada grupo, y **el número de iteraciones requeridas para la convergencia del algoritmo**. Esta aproximación multi-métrica permite una selección más robusta del k óptimo, ya que

diferentes métricas pueden favorecer distintos valores y el consenso entre ellas proporciona mayor confianza en la decisión final.

Los resultados obtenidos para las métricas totales calculadas son las siguientes:

TABLA COMPARATIVA DE MÉTRICAS					
K	Silhouette_Euclidean	Silhouette_Cosine	WSSSE_Inertia	Iterations	WSSSE_Change_%
2	0.846947	0.415669	3006.183527	7	NaN
3	0.649409	0.465717	2278.396101	20	-24.209680
4	0.648545	0.511747	2021.140842	12	-11.291068
5	0.594032	0.412354	1853.067511	20	-8.315765
6	0.633907	0.502625	1580.028600	12	-14.734429
7	0.599417	0.506008	1429.830581	12	-9.506032
8	0.611437	0.495604	1321.254686	12	-7.593620
9	0.557571	0.461446	1218.780995	20	-7.755786
10	0.611314	0.489592	1146.192802	20	-5.955803

Tabla 1. Comparativa de métricas de cada K (Clustering k-means)

En la tabla anterior se evidencia una tensión clara entre **simplicidad y calidad de segmentación**. La configuración con k=2 obtiene el Silhouette Score euclidiano más alto (0.847), indicando una separación geométrica excepcional entre solo dos grupos de escuelas (presumiblemente "baja criminalidad" vs. "alta criminalidad"), sin embargo, el Silhouette Score obtenido por coseno resulta ser el más bajo de todas la configuración.

Por otro lado, k=3 y k=4 emergen como candidatos equilibrados: k=3 logra la mayor reducción de WSSSE (-24.2%), sugiriendo que el tercer cluster añade información sustancial, mientras que k=4 alcanza el Silhouette coseno más alto (0.512), indicando mejor captura de patrones direccionales de criminalidad. Ambos convergen eficientemente (12-20 iteraciones), señalando estructuras estables en los datos.

Por último y antes de realizar la elección final se calcula una métrica más, la cuál es la técnica denominada “método del codo”, de la cuál se obtiene la siguiente visualización:




Figura 2. Método del codo (clustering k-means)

El método del codo revela una disminución progresiva del WSSSE a medida que aumenta k , donde el cambio más pronunciado ocurre en la transición de $k=2$ a $k=3$, con una reducción del 24.2% que representa la mayor ganancia en compacidad de clusters. Aunque la curva no presenta un "codo" abrupto y perfectamente definido, se observa que a partir de $k=3$ la pendiente comienza a suavizarse significativamente.

Este comportamiento, combinado con el sólido Silhouette Score euclidiano de $k=3$ (0.649) que supera consistentemente a configuraciones más complejas, la eficiencia computacional demostrada por su convergencia en 20 iteraciones, y la ventaja interpretativa de tres categorías naturales (escuelas de baja, media y alta criminalidad) que facilitan la implementación de políticas públicas diferenciadas, fundamenta **la selección de $k=3$ como configuración óptima.**

Una vez determinado esto, se procede a realizar el entrenamiento del modelo, del cuál se puede obtener los centros de los clústers y de acuerdo a estos caracterizar las agrupaciones que realizó el modelo.

3. Resultados obtenidos de la aplicación de la técnica

Teniendo lo anteriormente dicho en cuenta, al finalizar el entrenamiento, los perfiles identificados fueron los siguientes:

- **Cluster 0: Escuelas de Perfil Seguro (Baja Criminalidad)**

Este cluster agrupa escuelas que presentan valores consistentemente negativos en todas las dimensiones de criminalidad, indicando niveles por debajo del promedio del sistema escolar de NYC. Con un centroide de $[-0.36, -0.43, -0.32, -0.42, -0.39]$, estas instituciones registran aproximadamente un 40% menos incidentes que el promedio en crímenes mayores, violentos y de propiedad. Particularmente notable es el valor de -0.43 en "Otros Incidentes" (Oth_N), sugiriendo ambientes escolares con mínima conflictividad general. Estas escuelas representan el estándar de seguridad deseable y pueden servir como modelos de buenas prácticas en gestión de convivencia escolar, clima institucional y prevención. Su perfil homogéneamente bajo en todas las categorías sugiere que la seguridad en estos planteles no es resultado de la ausencia de un tipo específico de problema, sino de un ecosistema escolar integralmente funcional.

- **Cluster 1: Escuelas de Criminalidad Moderada (Perfil de Riesgo Intermedio)**

El cluster intermedio presenta un perfil diferenciado con valores moderadamente positivos en todas las variables $[0.59, 0.66, 0.32, 0.80, 0.50]$, situándose entre 30% y 80% por encima del promedio del sistema. Destaca especialmente el valor de 0.80 en crímenes de propiedad (Prop_N), indicando que estos planteles enfrentan desafíos particulares relacionados con robos, vandalismo o destrucción de bienes. El valor relativamente alto en "Otros Incidentes" (0.66) sugiere una conflictividad general elevada que, aunque no alcanza niveles críticos, requiere atención preventiva. Estas escuelas se encuentran en una zona de vulnerabilidad que puede escalar si no se implementan intervenciones focalizadas. Representan aproximadamente el punto medio del espectro de criminalidad escolar y constituyen candidatas prioritarias para programas de intervención temprana que eviten su deterioro hacia perfiles de mayor riesgo.

- **Cluster 2: Escuelas de Alta Conflictividad (Perfil de Riesgo Crítico)**

Este cluster identifica escuelas en situación crítica que requieren intervención urgente, con valores extremadamente elevados en todas las dimensiones $[2.37, 2.93, 2.75, 2.33, 2.96]$. Los centroides revelan niveles de criminalidad entre 2.3 y 3.0 desviaciones estándar por encima del promedio, lo que en términos prácticos significa que estas escuelas registran aproximadamente el triple de incidentes que una escuela promedio de NYC. Particularmente alarmantes son los valores de 2.96 en crímenes violentos (Vio_N) y 2.93 en otros incidentes (Oth_N), señalando ambientes escolares con violencia física recurrente y conflictividad generalizada. El valor de 2.75 en incidentes no criminales (NoCrim_N) sugiere además problemas sistémicos de disciplina y convivencia que trascienden lo delictivo. Estas instituciones concentran múltiples

factores de riesgo simultáneos y probablemente enfrentan desafíos estructurales complejos (ubicación en zonas de alta vulnerabilidad social, falta de recursos, rotación docente, infraestructura deficiente) que requieren intervenciones integrales multi-agencia coordinadas entre autoridades educativas, policiales y servicios sociales.

Dicho esto, ahora se procede a realizar una visualización gráfica que haga más clara la segmentación hecha por el algoritmo basada en el concepto de PCA, una técnica de reducción de dimensionalidad que convierte un conjunto de variables correlacionadas en nuevos ejes llamados componentes principales, los cuales capturan la mayor parte de la variabilidad de los datos. En este contexto en particular, **el PCA es útil porque permite visualizar en solo dos dimensiones la estructura interna del dataset de criminalidad escolar**, revelando patrones que no serían evidentes al observar las variables originales.




Figura 3. Visualización PCA de Clusters k-means

La visualización PCA revela una separación clara entre los tres clusters identificados por K-Means, demostrando que las diferencias en criminalidad escolar son consistentes y estructurales. El Cluster 0 (baja criminalidad) aparece como un grupo compacto hacia la derecha, reflejando entornos escolares homogéneamente seguros. El Cluster 1 (criminalidad moderada) se sitúa en la zona central con mayor dispersión, lo que evidencia su carácter intermedio y heterogéneo. Por su parte, el Cluster 2 (alta conflictividad) se ubica en el extremo izquierdo, bien aislado del resto, mostrando niveles excepcionalmente altos de incidentes en todas las categorías. En conjunto, el PCA confirma visualmente la solidez del modelo: los componentes principales

ordenan naturalmente a las escuelas en un continuo que va de contextos ejemplares a contextos críticos.


CONJUNTO DE DATOS DE POBREZA (DEEP LEARNING - BONO)

Para el dataset de pobreza se implementaron técnicas de Deep Learning, específicamente modelos supervisados basados en redes neuronales multicapa (MLP) o autoencoders. El uso de *deep learning* permite capturar relaciones no lineales y complejas entre variables, aportando una dimensión espacial y educativa más profunda al análisis integral del fenómeno delictivo. En este caso se va realizar la predicción de si un individuo es clasificado como pobre teniendo en cuenta diferentes variables.

A continuación se detalla el proceso que fue seguido para poder implementar esta técnica correctamente.

1. Preprocesamiento de datos

Antes de seleccionar las variables que predecían el estado de pobreza se comenzó por encontrar la correlación que existe en las variables, esto con el objetivo de no elegirlas, para esto se realiza una matriz de correlación. Utilizando las herramientas de PySpark y podemos calcular una matriz de correlación, que por medio de una escala de rojos y azules nos mostrará que tan fuerte es la correlación entre cada par de variables. La matriz de correlación para este conjunto de datos es la que se muestra a continuación:



En la matriz de correlación que se observa en la figura anterior se representa a través de una escala de colores el nivel numérico de correlación que hay entre cada par de variables, siendo que entre más se acerca a el color azul profundo, menor es la correlación entre dos variables; y por el contrario si la coloración se acerca más al rojo intenso, mayor es el nivel de correlación.

Como se puede evidenciar en esta tabla de pares correlacionados, existen múltiples correlaciones fuertes lo que puede presentar un problema a la hora de implementar modelos de aprendizaje de máquina.

A continuación se analizan detalladamente las correlaciones fuertes halladas:

Correlación de ingresos

Las variables NYCgov_Income, PreTaxIncome_PU y EST_IncomeTax presentan parte de las correlaciones más fuertes observadas, lo cuál hace sentido siendo que las tres contienen datos relacionados a los ingresos de los individuos.

Correlación de edades

Las variables AGEp, AgeCateg y AgeCategoryArrest presentan una correlación fuerte. Esto se debe a que todas contienen información relacionada a las edades de los individuos, siendo AGEp aquella que contiene las edades en particular, AgeCateg la que contiene la clasificación de edades para este dataset y AgeCategoryArrest la variable creada para la estandarización realizada previamente en este cuaderno.

Correlación de educación

Las variables EducationAttain y SCHL presentan una correlación alta debido a que el nivel educativo (EducationAttain) y los logros alcanzados en este ámbito (SCHL) están directamente relacionados.

Correlación de escolaridad actual

Las variables SCH y SCHG presentan una alta correlación, esto debido a que una hace referencia a si un individuo está matriculado en una institución educativa y la otra al grado escolar en el que se encuentra (si es que está matriculado).

2. Selección y limpieza de datos

Para la aplicación del modelo de aprendizaje profundo se requiere contar con una cantidad de datos suficientemente grande para que la red neuronal pueda aprender patrones robustos y relaciones complejas entre las variables. En este caso, el conjunto de datos de pobreza cuenta con 68.273 registros, lo cual representa un tamaño adecuado tanto para el entrenamiento como para el procesamiento distribuido del cluster Spark.

Con los datos disponibles, el siguiente paso consistió en seleccionar las variables más adecuadas para predecir si un individuo se encuentra en estado de pobreza. Esta selección se realizó considerando tres criterios principales:

1. **Relevancia teórica:** la literatura sobre pobreza y exclusión social identifica ciertos factores como determinantes clave del estado de vulnerabilidad económica.
Fuentes: <https://www.irp.wisc.edu/>
2. **Correlación observada en el dataset:** se dió prioridad a variables que mostraban relaciones significativas con el estado de pobreza o sus indicadores auxiliares (brecha de pobreza, ingresos ajustados, ayudas públicas, etc.).
3. **Diversidad de dimensiones:** se incluyeron variables económicas, educativas, lingüísticas, demográficas y familiares para capturar diferentes aspectos del fenómeno de la pobreza.

A continuación se describe brevemente cada variable seleccionada y la razón de su inclusión.

- **AGEP (Edad del individuo):** La edad incide directamente en la situación económica: los menores dependen completamente del hogar, los adultos jóvenes pueden tener ingresos inestables y los mayores de 65 años suelen vivir con ingresos fijos o pensiones reducidas. Su correlación con indicadores económicos la convierte en una variable clave.
- **EST_PovGapIndex (Índice de brecha de pobreza):** Mide qué tan lejos está un hogar del umbral de pobreza. Es un indicador continuo y altamente informativo que representa directamente el nivel de vulnerabilidad económica.
- **EST_Housing (Ajuste de ingresos por vivienda):** Los costos asociados a la vivienda suelen ser el gasto familiar más significativo. Un mayor ajuste implica mayor presión económica sobre el hogar, incrementando la probabilidad de pobreza.
- **NYCgov_Income (Ingreso ajustado según criterios de pobreza de NYC):**
Esta variable representa el ingreso total ajustado por la metodología de pobreza de la ciudad. Es probablemente una de las variables con mayor poder predictivo, ya que se relaciona directamente con la clasificación final del estado de pobreza.
- **RNTP_adj (Alquiler ajustado):** El alquiler mensual ajustado es un componente importante del balance económico del hogar. Comparado con los ingresos, permite identificar situaciones críticas de gasto que dificultan superar el umbral de pobreza.
- **EST_Nutrition (Ajustes relacionados con ayudas nutricionales):** Hogares que reciben apoyo alimentario (SNAP, WIC, comidas escolares) presentan mayor probabilidad de vulnerabilidad económica. Esta variable captura señales socioeconómicas adicionales relacionadas con pobreza estructural.

3. Limpieza de valores nulos

Según las especificaciones del ACS y del NYCgov Poverty Measure, algunas variables del dataset utilizan el valor **0** como código especial para representar “N/A” o “no aplica”. Este tipo de codificación puede confundir al modelo, ya que un “0” podría interpretarse accidentalmente como un valor válido dentro de la escala normal de la variable.

Las variables afectadas incluyen:

- **ENG:** N/A en menores de 5 años o personas que hablan únicamente inglés.
- **LANX:** N/A en menores de 5 años.
- **MSP:** N/A en personas menores de 15 años.

- **RNTP_adj**: N/A en unidades no alquiladas (vacantes, propias o sin pago).
- **EST_Housing**: N/A cuando el hogar no recibe subsidios de vivienda.
- **EST_Nutrition**: N/A cuando no se recibe ningún tipo de beneficio alimentario.

Para evitar que el modelo interprete estos valores de forma incorrecta, se aplicó una limpieza específica según el tipo de variable:

Variables categóricas:

Para las variables categóricas que utilizan el “0” como código de “no aplica”, se reemplazó dicho valor por una categoría adicional denominada 99.

Esto permite que el modelo distinga explícitamente los casos donde la información no es válida o no se aplica, sin mezclarlos con categorías reales.

Variables numéricas:

En el caso de las variables numéricas, no es adecuado reemplazar los ceros directamente con un valor arbitrario, ya que esto puede alterar la distribución. Por esta razón, se aplicó un enfoque en dos pasos:

1. Creación de una columna indicadora (_wasNA):

Se generó una nueva variable binaria que toma el valor 1 si la variable original tenía un “0” que representa un NA, y 0 en caso contrario. Esto permite conservar información sobre la ausencia del dato.

2. Imputación del valor promedio:

Los valores “0” considerados como NA fueron reemplazados por la **media** de cada variable. Esto mantiene la consistencia estadística del conjunto de datos sin introducir sesgos significativos.

Con este proceso, el modelo recibe datos más consistentes y con significado claro, evitando que los valores “0” distorsionen el aprendizaje del MLP.

4. Normalización de variables numéricas

Las variables numéricas del dataset provienen de diferentes escalas y magnitudes. Algunas representan cantidades pequeñas, como la brecha relativa de pobreza, mientras que otras pueden alcanzar valores muy elevados, como el ingreso total del hogar. Por ejemplo:

- La edad (AGEP) toma valores entre 0 y aproximadamente 90 años.
- El ingreso ajustado del hogar (NYCgov_Income) puede superar los 200.000 dólares.
- El alquiler ajustado (RNTP_adj) varía entre montos pequeños y miles de dólares mensuales.

Estas diferencias en magnitud generan un problema importante para los modelos de aprendizaje profundo: una variable con valores más grandes puede dominar el cálculo de los pesos de la red neuronal, dificultando el proceso de optimización, generando inestabilidad en el entrenamiento e incluso impidiendo la convergencia del modelo.

Para evitar este problema, se aplicó la técnica `StandardScaler`, que estandariza todas las variables numéricas de manera que tengan:

- Media igual a 0
- Desviación estándar igual a 1

Al normalizar de esta forma, todas las variables entran a la red en una escala comparable, permitiendo que el modelo aprenda patrones de forma equilibrada y sin que ninguna característica sobresalga artificialmente debido a su magnitud original.

5. Pipeline Final

Luego de definir todas las etapas del preprocesamiento, se integraron todas las transformaciones dentro de un Pipeline de PySpark.

Una vez definido, el pipeline se ajustó (`fit`) utilizando el dataframe original y generó un nuevo dataframe procesado que incluye la columna `features`, la cual contiene toda la información lista y transformada para ser utilizada por el modelo `Multilayer Perceptron`.

Este vector de características constituye la entrada final de la red neuronal y representa la combinación completa de variables numéricas normalizadas, variables categóricas codificadas y los indicadores añadidos durante la limpieza de datos.

6. Entrenamiento del modelo

Ahora se aplica el modelo **Multilayer Perceptron Deep Neural Network** para realizar la predicción del estado de pobreza.

El primer paso consiste en dividir el conjunto de datos en dos subconjuntos:

- **Entrenamiento:** utilizado para ajustar los pesos internos de la red neuronal.
- **Prueba:** datos nunca vistos por el modelo, utilizados para evaluar su capacidad de generalización.

Durante esta etapa también se calcula el número total de características de entrada (features), las cuales corresponden al vector generado después del preprocesamiento. Este valor define el tamaño de la capa de entrada de la red neuronal.

Resultados obtenidos:

- **Número total de features:** 53
- **Cantidad de datos totales:** 68.273 registros
- **Datos de entrenamiento:** 54.755 registros
- **Datos de prueba:** 13.518 registros

Este tamaño de muestra es adecuado para entrenar un modelo de aprendizaje profundo dentro del entorno distribuido de PySpark, garantizando estabilidad y capacidad de generalización.

7. Estructura del modelo

Antes de entrenar la red neuronal multicapa, se debe definir su arquitectura.

En PySpark, esta arquitectura se especifica mediante una lista denominada **layers**, donde cada elemento representa el número de neuronas por capa, en el orden en que serán procesadas.

En este caso, la estructura elegida fue:

layers = [input_dim, 64, 32, 2]

Esto corresponde a:

- **Capa de entrada:** contiene una neurona por cada característica del vector *features* (numéricas normalizadas, variables categóricas codificadas y variables indicadoras).
- **Primera capa oculta (64 neuronas):** permite al modelo aprender combinaciones no lineales de las variables de entrada.

- **Segunda capa oculta (32 neuronas):** profundiza en patrones de interacción más complejos y refina la información generada por la capa anterior.
- **Capa de salida (2 neuronas):** representa las dos clases del problema:
 - 0 = No pobreza
 - 1 = En pobreza

Esta configuración busca un equilibrio entre capacidad expresiva y eficiencia computacional, evitando tanto el subajuste como el sobreajuste.

8. Creación del modelo de Deep Learning

Una vez definida la arquitectura, se procede a construir el modelo utilizando la clase **MultilayerPerceptronClassifier** de PySpark MLlib. Este algoritmo implementa una red neuronal multicapa diseñada específicamente para tareas de clasificación supervisada.

El modelo incluye parámetros importantes como:

- **maxIter = 50:** número de iteraciones de entrenamiento.
- **blockSize = 128:** tamaño del lote de datos procesados en cada paso.
- **seed = 42:** para garantizar reproducibilidad.

El **MultilayerPerceptronClassifier** emplea por defecto la función de activación **sigmoidal** en sus capas ocultas. Esta función transforma la salida lineal de cada neurona en un valor entre 0 y 1, introduciendo no linealidad al modelo.

El optimizador para entrenamiento del MLP se realiza mediante una variante del algoritmo **L-BFGS** (Limited-memory Broyden–Fletcher–Goldfarb–Shanno). El cual permite que el modelo encuentre de manera efectiva los parámetros que minimizan la función de pérdida, garantizando un entrenamiento consistente y de alta calidad.

9. Entrenamiento del modelo

Una vez definida la arquitectura del Multilayer Perceptron y preparado el conjunto de datos mediante el pipeline, se procede a entrenar el modelo utilizando exclusivamente los datos del conjunto de entrenamiento. Durante esta fase, la red neuronal ajusta sus pesos internos mediante el algoritmo de optimización L-BFGS, buscando minimizar la función de pérdida asociada al problema de clasificación.

Tras finalizar el entrenamiento, el modelo se aplica sobre el conjunto de prueba (el conjunto de datos sobre el que no se entreno), que ejecuta la red neuronal para cada

observación del dataset y genera las columnas de salida correspondientes, incluyendo la predicción final y la probabilidad asignada por el modelo a cada clase.

10. Evaluación del modelo

Evaluar adecuadamente un modelo de aprendizaje profundo es esencial para determinar su capacidad real para clasificar correctamente nuevos individuos. En este proyecto se emplearon dos métricas fundamentales: **Accuracy** y **F1-Score**, calculadas mediante el `MulticlassClassificationEvaluator` de PySpark, además de una matriz de confusión para analizar en detalle los aciertos y errores.

Accuracy

El *accuracy* mide la proporción total de predicciones correctas con respecto al número total de observaciones evaluadas. En otras palabras, indica qué porcentaje de individuos fueron clasificados correctamente como “en pobreza” o “no en pobreza”.

Un accuracy alto sugiere que el modelo logra capturar los patrones generales del dataset. Sin embargo, debe interpretarse con cuidado cuando existe desbalance entre clases, ya que podría ocultar errores en la clase minoritaria.

- **Accuracy obtenido:** 0.9969670069536913

Este valor indica un desempeño extremadamente alto, con menos de un 0.4% de errores en la clasificación.

F1-Score

El F1-Score es especialmente importante en problemas de clasificación donde las clases no están balanceadas, como es frecuente en estudios de pobreza.

Esta métrica combina dos medidas críticas:

- **Precisión:** proporción de predicciones positivas que son correctas.
- **Exhaustividad:** proporción de casos positivos que fueron identificados correctamente.

El F1-Score es la media entre ambas, lo que ofrece una visión mucho más equilibrada del rendimiento del modelo, evitando que una métrica alta o baja domine el resultado.

- **F1-Score obtenido:** 0.9969581971761218

Este valor confirma que el modelo no solo clasifica bien en general, sino que logra identificar correctamente tanto a los individuos pobres como a los no pobres.

Matriz de confusión

La matriz de confusión permite analizar detalladamente cómo se comporta el modelo en cada clase del problema.

Este es un recurso fundamental para entender los errores específicos del modelo:

- **Verdaderos positivos (VP):** individuos pobres correctamente clasificados como pobres.
- **Verdaderos negativos (VN):** individuos no pobres correctamente clasificados como no pobres.
- **Falsos positivos (FP):** individuos no pobres clasificados erróneamente como pobres.
- **Falsos negativos (FN):** individuos pobres clasificados erróneamente como no pobres.

En este caso la etiqueta 1, representa estado de pobreza y 0 no estado de pobreza.

Etiqueta	Predicción	Conteo
1.0	1.0	2351
1.0	0.0	38
0.0	0.0	11126
0.0	1.0	3

El modelo clasificó correctamente 2351 personas en pobreza, con solo 38 falsos negativos, lo cual es particularmente importante porque no identificar a un individuo en pobreza puede tener consecuencias analíticas significativas.

En la clase “no pobreza”, el modelo tuvo un desempeño excelente, con más de 11.000 clasificaciones correctas y solo 3 falsos positivos.

Esto evidencia que el modelo es altamente confiable, tanto para identificar pobreza como para reconocer correctamente a quienes no se encuentran en esa condición.

Gráficas:


Con el fin de complementar las métricas numéricas y la matriz de confusión, se realizaron dos visualizaciones que permiten entender de manera más intuitiva cómo se comportó el modelo al clasificar a los individuos del conjunto de prueba.

Distribución de clases reales en el conjunto de prueba:

La primera gráfica muestra la cantidad de individuos pertenecientes a cada clase del problema:

- **Clase 0.0:** No pobreza
- **Clase 1.0:** En pobreza

En rojo se muestran las predicciones correctas y en anaranjado las incorrectas:



Como se puede evidenciar, la gran mayoría de los datos se encuentran en lo azul. Lo que demuestra una gran precisión del modelo.


Además se puede notar que existe un desbalance natural en los datos, donde la mayoría de los individuos se encuentran en la categoría “no pobreza”. Por lo que podemos suponer que la mayoría de los que se encuentran en esta base de datos son pobres.

Aciertos y errores del MLP sobre el conjunto de prueba

La segunda gráfica representa cada observación del conjunto de prueba, diferenciando entre:

- **Predicciones correctas:** puntos verdes
- **Predicciones incorrectas:** cruces rojas

El eje Y indica la clase real (0 = no pobre, 1 = pobre), mientras que cada punto del eje X corresponde a una observación distinta.



Esta visualización permite observar:

- Una **casi totalidad de puntos verdes**, lo cual concuerda con los valores obtenidos en precisión y F1.
- Un número **muy reducido de errores**, visibles como pequeños puntos rojos dispersos.
- Que los errores aparecen tanto en la clase “no pobreza” como en la clase “pobreza”, pero en cantidades insignificantes.

La gráfica confirma visualmente la robustez del modelo y su excelente desempeño para ambas clases.

11. Uso de otros parámetros

Con el objetivo de explorar posibles mejoras en el rendimiento del modelo y evaluar su sensibilidad ante distintas configuraciones, se realizaron pruebas adicionales variando los hiperparámetros del MultilayerPerceptronClassifier.

En particular, se modificaron aspectos relacionados con la arquitectura de la red y el proceso de entrenamiento:

- **Arquitecturas más simples:** menor número de neuronas o solo una capa oculta. (Capas: [input_dim, 32, 2], Iteraciones: 100)
- **Arquitecturas más anchas:** capas con más neuronas. (Capas: [input_dim, 128, 64, 2], Iteraciones: 100)
- **Arquitecturas más profundas:** mayor número de capas ocultas. (Capas: [input_dim, 128, 64, 32, 2], Iteraciones: 100)

- **Aumento en el número de iteraciones:** ciclos adicionales de entrenamiento para permitir una convergencia más fina. (Capas: [input_dim, 128, 64, 32, 2], Iteraciones: 100)

Resultados:

Configuración	Accuracy	F1-Score
Simple	0.99793	0.99793
Wide	0.99645	0.99644
Deep	0.99645	0.99644
Deep - Iter	0.99852	0.99851

Todas las configuraciones presentan un rendimiento excelente, con valores de accuracy y F1 superiores al 99.6%. Esto confirma que el MLP es altamente efectivo para capturar las relaciones socioeconómicas del dataset de pobreza.

La **arquitectura simple** obtuvo uno de los mejores resultados, lo que sugiere que el problema no requiere redes muy profundas ni complejas. El dataset parece presentar patrones suficientemente claros para que una red poco profunda los aprenda de manera efectiva.

Las arquitecturas **wide** y **deep** no lograron mejoras significativas respecto al modelo base.

Esto indica que aumentar el número de neuronas o capas no necesariamente aporta un beneficio adicional en este caso.

La configuración **deep-iter**, que combina una arquitectura profunda con un mayor número de iteraciones, presentó el mejor rendimiento global.

Sin embargo, la mejora frente a la arquitectura simple es marginal (+0.0006).

Esto sugiere que el modelo puede beneficiarse ligeramente de un entrenamiento más prolongado, pero que dichas mejoras no justifican necesariamente un aumento

considerable en el costo computacional, especialmente en entornos distribuidos donde el tiempo de ejecución es un factor relevante.

Conclusión de la aplicación del modelo

La aplicación del modelo de aprendizaje profundo sobre el conjunto de datos de pobreza permitió demostrar la capacidad del Multilayer Perceptron para identificar de manera precisa y consistente los factores asociados al estado de pobreza de un individuo.

Los resultados obtenidos revelan un desempeño sobresaliente, con métricas superiores al 99.6% en todas las configuraciones evaluadas. Esta estabilidad sugiere que el problema presenta patrones claros y que el MLP es suficientemente expresivo para capturar las relaciones socioeconómicas presentes en el dataset. Además, la comparación entre arquitecturas simples, anchas y profundas mostró que las mejoras marginales no justifican arquitecturas complejas ni costos computacionales elevados.

En conjunto, el estudio confirma que el aprendizaje profundo es una metodología eficaz y robusta para la predicción del estado de pobreza, logrando una generalización notable incluso en un escenario con desbalance de clases. Esto abre la puerta a futuras aplicaciones basadas en modelos más interpretables, análisis contrafactuales o sistemas que combinen aprendizaje profundo con técnicas explicativas para apoyar la toma de decisiones en políticas públicas y análisis social.

CONCLUSIONES

A partir de todo el análisis realizado, es evidente que la criminalidad en Nueva York no está distribuida al azar, sino que se concentra de manera muy clara en los territorios donde también se acumulan las mayores desventajas sociales. El Bronx y Brooklyn aparecen de forma recurrente como los distritos con más arrestos, mayores brechas de pobreza y más incidentes de criminalidad escolar, mientras que Staten Island y Queens se ubican en el extremo opuesto. Esto confirma que la pobreza y la desigualdad no son solo un “contexto” de fondo, sino factores que están directamente relacionados con la probabilidad de tener contacto con el sistema penal y de estudiar en entornos escolares más conflictivos.

El papel de la educación también resulta clave. En general, los distritos con menores niveles educativos promedio —especialmente el Bronx— tienden a concentrar más arrestos y más crímenes escolares, lo que sugiere que la educación sí funciona como un factor protector. Sin embargo, casos como el de Manhattan, donde coexisten altos niveles educativos con una criminalidad asociada a la dinámica económica y comercial, muestran que la educación por sí sola no basta para compensar las brechas estructurales. Para la Alcaldía, esto implica que las políticas educativas deben ir de la mano de intervenciones sociales y económicas más amplias, orientadas a cerrar la brecha entre barrios y no solo a mejorar indicadores dentro de las escuelas.

Los modelos de machine learning que se aplicaron ayudan a aterrizar estas ideas. El Random Forest usado con los datos de arrestos mostró que, con la información disponible, es difícil predecir con precisión el tipo de delito, lo que sugiere que detrás de cada arresto hay factores que hoy no están siendo medidos (historia laboral, condiciones familiares, acceso a redes de apoyo, etc.). En contraste, el modelo de deep learning para pobreza sí logra identificar patrones muy claros sobre quién está en situación de pobreza y quién no. Esto envía un mensaje importante a la Alcaldía: la pobreza no es un fenómeno “difuso”, sino que tiene perfiles muy definidos que pueden detectarse con datos y utilizarse para focalizar mejor los programas sociales.

El ejercicio de clustering con las escuelas refuerza aún más esta idea de focalización. El modelo identifica tres tipos de planteles: escuelas relativamente seguras, escuelas con riesgo intermedio y escuelas con niveles críticos de conflictividad. Esto abre la puerta para que la Alcaldía deje de tratar a todas las instituciones por igual y reconozca que hay grupos de escuelas que necesitan intervenciones urgentes y más intensivas (acompañamiento psicosocial, trabajo con familias, refuerzo de equipos de convivencia, articulación con policía comunitaria y servicios sociales), mientras que otras pueden funcionar como referentes de buenas prácticas.

Con base en estos hallazgos, el mensaje para la Alcaldía de Nueva York es claro. Primero, se deben priorizar de manera explícita los distritos donde se superponen pobreza, alta criminalidad y problemas escolares —principalmente el Bronx y Brooklyn—, concentrando allí los esfuerzos de inversión social, programas de empleo juvenil, acceso a vivienda digna y fortalecimiento de las redes comunitarias. Segundo, es necesario apostar por una política educativa más integral en estos territorios: ampliar programas de permanencia escolar, tutorías y rutas claras hacia la educación superior, pero también trabajar con las familias para que la escuela no sea el único espacio de contención. Tercero, la segmentación de escuelas obtenida con el modelo de clustering debería usarse como insumo directo para asignar recursos: más personal de apoyo, programas de mediación de conflictos y proyectos de prevención de violencia en las instituciones identificadas como de alta conflictividad.

Finalmente, los buenos resultados del modelo de pobreza muestran que la Alcaldía puede incorporar de manera permanente este tipo de herramientas analíticas en su gestión. Crear un observatorio de datos que integre arrestos, educación y pobreza permitiría monitorear en tiempo real qué barrios se están deteriorando, qué escuelas están empeorando sus indicadores y si las políticas que se implementan están teniendo efecto. En otras palabras, el reto para la ciudad ya no es solo “combatir el delito”, sino intervenir preventivamente las condiciones que lo producen. Si la Alcaldía utiliza esta evidencia para orientar decisiones y coordinar de forma más estrecha las agendas de seguridad, educación y desarrollo social, Nueva York tendría la posibilidad real de reducir, de manera sostenible, tanto la criminalidad urbana como la escolar en los próximos años.

REFERENCIAS

- Stenkamp, A., & Rempel, M. (s/f). *Racial and neighborhood disparities in New York city criminal summons practices*. [Datacollaborativeforjustice.org](https://datacollaborativeforjustice.org). Recuperado el 21 de octubre de 2025, de https://datacollaborativeforjustice.org/wp-content/uploads/2024/02/Criminal_Summons_Disparities_Report.pdf
- (S/f). Nyc.gov. Recuperado el 21 de octubre de 2025, de https://www.nyc.gov/assets/ccrb/downloads/pdf/policy_pdf/annual_bi-annual/2024-C-CRB-Annual-Report.pdf
- Bratton, W. J. (s/f). Broken windows and quality-of-life policing in New York city. Nyc.gov. Recuperado el 21 de octubre de 2025, de https://www.nyc.gov/html/nypd/downloads/pdf/analysis_and_planning/qol.pdf
- The civil rights implications of “broken windows” policing in NYC and general NYPD accountability to the public. (2018). Usccr.gov. <https://www.usccr.gov/files/pubs/2018/03-22-NYSAC.pdf>
- News 12 New York. (13 de diciembre de 2023). “Leaked NYPD report reveals schools with biggest crime issues”. <https://longisland.news12.com/leaked-report-from-nypd-school-safety-division-reveals-schools-with-biggest-crime-issues>
- *NYS Open Legislation* | *NYSenate.gov*. (s. f.). <https://www.nysenate.gov/legislation/laws/PEN/P3TJA155>
- Amazon Web Services, Inc. (s. f.). *Funcionamiento de la agrupación en clústeres de k-means*. Recuperado de https://docs.aws.amazon.com/es_es/sagemaker/latest/dg/algo-kmeans-tech-notes.html
- Kavlakoglu, E., & Winland, V. (s. f.). *¿Qué es la agrupación en clústeres k-means?* IBM. Recuperado de <https://www.ibm.com/mx-es/think/topics/k-means-clustering>